


النوع Gradient Descent iterative على مرنه وبالمعادلة ان مرنه

(٢)

نبدأ من نقطة ما ثم نسير الى نقطة minimum . نسير بخطوات gradient

تبع دالة التكلفة الى ان نصل الى minimum .



$$\frac{\partial J(w, b)}{\partial w} = \frac{\partial}{\partial w} \frac{1}{2} (h(x) - y)^2 = (h(x) - y) \frac{\partial}{\partial w} (h(x) - y)$$

$$= (h(x) - y) \frac{\partial}{\partial w} \left(\frac{e^{wx+b}}{1 + e^{wx+b}} \right)$$

$$= (h(x) - y) \left(\frac{x e^{wx+b}}{(1 + e^{wx+b})^2} \right)$$

$$= (h(x) - y) \left(\frac{x e^{wx+b}}{1 + e^{wx+b}} \right) \left(1 - \frac{e^{wx+b}}{1 + e^{wx+b}} \right)$$

$$= x (h(x) - y) \left(\frac{e^{wx+b}}{1 + e^{wx+b}} \right) \left(1 - \frac{e^{wx+b}}{1 + e^{wx+b}} \right)$$

$$= x (h(x) - y) (h(x)) (1 - h(x))$$

$$\frac{\partial J(w, b)}{\partial b} = \frac{\partial}{\partial b} \frac{1}{2} (h(x) - y)^2 = (h(x) - y) \frac{\partial}{\partial b} (h(x) - y)$$

$$= (h(x) - y) \frac{\partial}{\partial b} \left(\frac{e^{wx+b}}{1 + e^{wx+b}} \right)$$

$$= (h(x) - y) \left(\frac{e^{wx+b}}{(e^{wx+b} + 1)^2} \right) = (h(x) - y) (h(x)) (1 - h(x))$$

α : learning rate

$$w := w - \alpha \frac{\partial}{\partial w} J(w, b)$$

$$b := b - \alpha \frac{\partial}{\partial b} J(w, b)$$

$$\hat{Y} = \alpha + \beta X$$

$$E[\hat{Y}] = E[\alpha + \beta X] = \beta E[X] + \alpha = \beta \mu_X + \alpha$$

$$E[Y - \hat{Y}] = E[Y] - E[\hat{Y}] = \mu_Y - \beta \mu_X - \alpha$$

$$\text{Var}(Y - \hat{Y}) = E[(Y - \hat{Y})^2] - (E[Y - \hat{Y}])^2$$

$$= \text{Var}(Y) + \text{Var}(\hat{Y}) - 2\text{Cov}(Y, \hat{Y})$$

$$= \text{Var}(Y) + \text{Var}(\hat{Y}) - 2\text{Cov}(Y, \alpha + \beta X)$$

$$= \text{Var}(Y) + \text{Var}(\hat{Y}) - 2\text{Cov}(Y, X)$$

$$\text{Var}(\hat{Y}) = \text{Var}(\alpha + \beta X) = \beta^2 \text{Var}(X) = \beta^2 \delta_X^2$$

$$\begin{aligned} \Rightarrow \text{Var}(Y - \hat{Y}) &= \delta_Y^2 + \beta^2 \delta_X^2 - 2\beta \text{Cov}(X, Y) \\ &= \delta_Y^2 + \beta^2 \delta_X^2 - 2\beta \delta_{XY} \end{aligned}$$

$$\Rightarrow \downarrow E[(Y - \hat{Y})^2] = \beta^2 \delta_X^2 + \delta_Y^2 - 2\beta \delta_{XY} + (\mu_Y - \beta \mu_X - \alpha)^2 \downarrow$$

$$\text{minimize} \Rightarrow \mu_Y - \beta \mu_X - \alpha = 0 \rightarrow \alpha = \underline{\mu_Y - \beta \mu_X}$$

حال که تکلیف α مشخص شده است با جایگذاری α عبارت $E[(Y - \hat{Y})^2]$ به یک تابع با آرگومان β تبدیل می شود. (با توجه به ثابت بودن μ_X و μ_Y و ... همگی مشخص و ثابت هستند) پس σ و μ را می توانیم به β برای بهینه سازی از عبارت زیر

$$E[(Y - \hat{Y})^2] = \beta^2 \delta_X^2 + \delta_Y^2 - 2\beta \delta_{XY} \quad \text{رابطه به دست آمده}$$

$$\xrightarrow{\frac{d}{d\beta} = 0} 2\beta \delta_X^2 - 2\delta_{XY} = 0 \rightarrow \beta = \frac{2\delta_{XY}}{2\delta_X^2} = \frac{\delta_{XY}}{\delta_X^2}$$

$$\begin{aligned} \frac{\text{Var}(Y) - \text{Var}(Y - \hat{Y})}{\text{Var}(Y)} &= \frac{\delta_Y^2 - (\delta_Y^2 - \beta^2 \delta_X^2 + 2\beta \delta_{XY})}{\delta_Y^2} \xrightarrow{\text{جایگذاری}} \frac{-\delta_{XY}^2}{(\delta_X^2)^2} \delta_X^2 + \frac{2\delta_{XY}^2}{\delta_X^2} \\ &\rightarrow = \frac{\delta_{XY}^2}{\delta_X^2 \delta_Y^2} = r_{XY}^2 \end{aligned}$$

* Least squares estimation

$$Y = f(x) + \text{noise} \xrightarrow[\text{Squares}]{\text{least}} \sum_{i=1}^n (y_i - f_b(x_i))^2 : \|y - Xb\|^2$$

$$f(x) = \beta_0 x + \beta_1 x^2$$

$$X = \begin{pmatrix} x_{1,1} & x_{1,2} \\ \vdots & \vdots \\ x_{n,1} & x_{n,2} \end{pmatrix} = (x_1 \quad x_2) \text{ و } n = k+1$$

باقی به بحث های انجام شده در کلاس در رابطه با اثبات Maximum Likelihood (رابطه نرنال)

$$\hat{\beta} = (X'X)^{-1} X'y$$

پس به این ترتیب به تعیین پارامترها می رسید.

ماتریس covariance برابر است با:

$$(X'X)^{-1} \sigma^2$$

که σ^2 در اینجا واریانس noise ها می باشد که برابر است با: (که estimator برای آنکه تعیین می کنیم)

$$\hat{\sigma}^2 = \frac{1}{n-p} \|y - X\hat{\beta}\|^2 = \frac{1}{n-p} \sum_{i=1}^n \hat{e}_i^2$$

$$n = k+1$$

$$p=2$$

که \hat{e}_i ها برابر اند با:

$$\hat{e}_i = y_i - f(x_i)$$

حال به اثبات این رابطه می پردازیم.

$$\text{if } \begin{cases} 1. Y = \beta X + \varepsilon \\ 2. E[\varepsilon|X] = 0 \\ 3. \text{Cov}(\varepsilon|X) = \sigma^2 I = V(\varepsilon|X) \\ 4. \text{estimator is unique (normal equation)} \end{cases}$$

$$\text{then } \text{Cov}(\beta|X) = \sigma^2 (X'X)^{-1}$$

$$\begin{aligned} \text{proof: } \beta &= (X'X)^{-1} X'Y = (X'X)^{-1} X'(X\beta + \varepsilon) \\ &= (X'X)^{-1} X'X\beta + (X'X)^{-1} X'\varepsilon \\ &= \beta + (X'X)^{-1} X'\varepsilon \end{aligned}$$

Taking expectation of both sides gives you: estimator is unbiased

Taking variance of both sides gives you:

$$\begin{aligned} \text{Cov}(\beta) &= \text{Cov}(\beta|X) = \text{Cov}(\beta + (X'X)^{-1} X'\varepsilon | X) \\ &= \text{Cov}((X'X)^{-1} X'\varepsilon | X) \\ &= (X'X)^{-1} X' V(\varepsilon|X) X (X'X)^{-1} \\ &= (X'X)^{-1} X' \sigma^2 I X (X'X)^{-1} \\ &= \sigma^2 (X'X)^{-1} X' X (X'X)^{-1} \\ &= \sigma^2 (X'X)^{-1} \\ &= \sigma^2 (X'X)^{-1} \end{aligned}$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

$$\rightarrow MSE = \frac{1}{k+1} \sum_{i=1}^{k+1} (Y_i - (\beta X + \varepsilon))$$

$$= \frac{1}{k+1} \sum_{i=1}^{k+1} (Y_i - ((X'X)^{-1} X' Y_i X + \varepsilon))$$

در اینجا دقیقاً از روابط سوال ۴ استفاده خواهیم کرد :

$$y = \beta_1 x + \beta_0$$

x	y
4	31
9	58
10	65
14	73
4	37
7	44
12	60
22	91
1	21
17	84

$$\hat{\beta} = (X'X)^{-1} X'y$$

$$X = \begin{pmatrix} 1 & 4 \\ 1 & 9 \\ 1 & 10 \\ 1 & 14 \\ 1 & 4 \\ 1 & 7 \\ 1 & 12 \\ 1 & 22 \\ 1 & 1 \\ 1 & 17 \end{pmatrix}$$

$$\hat{\beta} = (X'X)^{-1} X'y \cong \begin{pmatrix} 21.69 \\ 3.47 \end{pmatrix} \begin{matrix} \rightarrow \beta_0 \\ \rightarrow \beta_1 \end{matrix}$$

$$E = y - \hat{y} = (y - (\beta_1 x + \beta_0)) = \begin{pmatrix} 31 - 35.57 \\ 58 - 52.92 \\ 65 - 56.4 \\ 73 - 70.38 \\ 37 - 35.57 \\ 44 - 45.28 \\ 60 - 63.34 \\ 91 - 98.04 \\ 21 - 25.16 \\ 84 - 80.69 \end{pmatrix} = \begin{pmatrix} -4.57 \\ 5.07 \\ 8.6 \\ 2.71 \\ 1.42 \\ -1.98 \\ -3.34 \\ -7.04 \\ -4.16 \\ 3.30 \end{pmatrix}$$

$$\sigma^2 = (X'X)^{-1} E^2 \Rightarrow \hat{\sigma}^2 = \frac{1}{10-2} \sum_{i=1}^{10} \hat{e}_i^2 \cong \frac{1}{8} (223.04) \cong 27.88$$

$$\sigma^2 = \begin{pmatrix} 10.20 & -0.74 \\ -0.74 & 0.074 \end{pmatrix}$$

$\text{Cov}(\beta_0, \beta_1) = -0.74$ $\text{Cov}(\beta_1, \beta_1) = \sigma^2_{\beta_1}$

$$\begin{cases} \text{Var}(\beta_0) = 10.20 \\ \text{Var}(\beta_1) = 0.074 \end{cases}$$

$$\text{Correlation} \rightarrow \rho(\beta_0, \beta_1) = \frac{\text{Cov}(\beta_0, \beta_1)}{\sigma_{\beta_1} \sigma_{\beta_0}} = \frac{-0.74}{\sqrt{10.20} \sqrt{0.074}} = -0.98$$